

Lista de exercícios 5

Mateus Costa 190047585

2024-06-19



UnB

Universidade de Brasília

Instituto de exatas

Departamento de estatística

Análise de séries temporais

Professor: Raul Yukihiro Matsushita

Leitura dos dados para os exercícios

```
dados <- read_excel("C:/Users/Ednalva/Downloads/ConsumoEnergiaEAgua_New.xlsx",  
  col_types = c("date", "date", "numeric", "numeric",  
    "numeric", "numeric", "numeric", "numeric",  
    "numeric", "numeric", "numeric"))
```

Questão 1


```
Xt <- na.omit(dados$Energia)  
Dt <- na.omit(dados$Dias)  
Yt <- Xt/Dt  
t <- na.omit(dados$mes)  
t <- t[-327]  
t <- t[-326]  
t <- t[-325]  
condados <- data.frame(t,Xt,Dt,Yt)
```

Com essa transformação se tem uma taxa de consumo médio, que pode ser acessada por diferenciação, facilitando a análise das série temporal.

Questão 2

```
getYt <- ggplot(data=condados, aes(x = t, y= Yt)) + geom_line() +  
  labs(y="Consumo medio de energia", x = "Mes") +  
  ggtitle("Gráfico de evolução temporal do consumo médio de energia")  
getYt
```

Gráfico de evolução temporal do consumo médio de energia




Série vai de junho de 1997 até maio de 2024, com periodicidade de 1 mês, totalizando 324 observações.

Questão 3


```
rho <- acf(condados$Yt, lag=length(condados$Yt), level = 95)
```

Series condados\$Yt



```
phi <- pacf(condados$Yt, lag=length(condados$Yt), level = 95)
```

Series condados\$Yt



Fac próximo de 1 com decaimento lento, indicando forte autocorrelação e não estacionaridade. Corte abrupto da FACP e próximo de 1 no lag*1), indicando não estacionaridade.

Questão 4

```
serie <- ts(condados$Yt, frequency = 12)
adf.test(serie)
```

```
## Augmented Dickey-Fuller Test
## alternative: stationary
##
## Type 1: no drift no trend
##   lag    ADF p.value
## [1,]  0 -0.995  0.323
## [2,]  1 -0.759  0.407
## [3,]  2 -0.527  0.490
## [4,]  3 -0.372  0.537
## [5,]  4 -0.224  0.580
## [6,]  5 -0.168  0.596
## Type 2: with drift no trend
##   lag    ADF p.value
## [1,]  0 -3.07  0.0311
## [2,]  1 -2.67  0.0846
```

```
## [3,] 2 -2.27 0.2197
## [4,] 3 -1.85 0.3849
## [5,] 4 -1.66 0.4617
## [6,] 5 -1.54 0.5077
## Type 3: with drift and trend
##      lag      ADF p.value
## [1,]  0 -3.427 0.0493
## [2,]  1 -2.667 0.2949
## [3,]  2 -1.892 0.6216
## [4,]  3 -1.153 0.9129
## [5,]  4 -0.608 0.9766
## [6,]  5 -0.292 0.9900
## ----
## Note: in fact, p.value = 0.01 means p.value <= 0.01
```

```
n <- length(condados$Yt)

harmonica <- data.frame(
  time = 1:n,
  cos1 = cos(2 * pi * (1:n) / 12),
  sin1 = sin(2 * pi * (1:n) / 12),
  cos2 = cos(4 * pi * (1:n) / 12),
  sin2 = sin(4 * pi * (1:n) / 12))

modeloharm <- lm(serie ~ cos1 + sin1 + cos2 + sin2, data=harmonica)
summary(modeloharm)
```

```
##
## Call:
## lm(formula = serie ~ cos1 + sin1 + cos2 + sin2, data = harmonica)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -14.0707  -6.3810   0.3832   5.8263  10.8314
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  14.30075    0.35438  40.354  <2e-16 ***
## cos1         0.17362    0.50117   0.346   0.729
## sin1         0.02458    0.50117   0.049   0.961
## cos2        -0.46512    0.50117  -0.928   0.354
## sin2         0.53422    0.50117   1.066   0.287
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 6.379 on 319 degrees of freedom
## Multiple R-squared:  0.006602, Adjusted R-squared:  -0.005855
## F-statistic: 0.53 on 4 and 319 DF, p-value: 0.7138
```

Com os resultados dos testes não há evidência estatística suficiente para considerar estacionaridade nem

sazonalidade.


Questão 5

```
condados$zt <- c(NA, diff(condados$Yt))
```

Com essa transformação é possível remover tendências, estabilizar a variância e transformar a série em estacionária.

Questão 6


```
getZt <- ggplot(data=condados, aes(x = t, y= zt)) +geom_line() +  
  labs(y="Variação de consumo medio de energia", x = "Mes") +  
  ggtitle("Gráfico de evolução temporal da variação do consumo de energia")  
getZt
```



Com a alteração a série vai de julho/97 até maio/24, totalizando 323 observações mensais. Diferente do gráfico do item 2, esse é centrado no valor 0 e tem uma variação menor, além de aparentemente não apresentar tendência.


Questão 7

```
rhozt <- acf(na.omit(condados$zt), lag=length(condados$zt), level = 95)
```



```
phizt <- pacf(na.omit(condados$zt), lag=length(condados$zt), level = 95)
```


Series na.omit(condados\$zt)



Fac distante de 1, indicando fraca autocorrelação negativa. Facp mostra uma forma de dependência autoregressiva com vários termos. Indicam estacionaridade.

```
seriezt <- ts(condados$zt, frequency = 12)
adf.test(seriezt)
```

```
## Augmented Dickey-Fuller Test
## alternative: stationary
##
## Type 1: no drift no trend
##      lag    ADF p.value
## [1,]  0 -22.2    0.01
## [2,]  1 -17.7    0.01
## [3,]  2 -15.6    0.01
## [4,]  3 -14.3    0.01
## [5,]  4 -12.3    0.01
## [6,]  5 -10.8    0.01
## Type 2: with drift no trend
##      lag    ADF p.value
## [1,]  0 -22.1    0.01
## [2,]  1 -17.6    0.01
## [3,]  2 -15.6    0.01
## [4,]  3 -14.3    0.01
## [5,]  4 -12.3    0.01
## [6,]  5 -10.7    0.01
```

```
## Type 3: with drift and trend
##      lag    ADF p.value
## [1,]  0 -22.2    0.01
## [2,]  1 -17.7    0.01
## [3,]  2 -15.7    0.01
## [4,]  3 -14.5    0.01
## [5,]  4 -12.5    0.01
## [6,]  5 -11.0    0.01
## ----
## Note: in fact, p.value = 0.01 means p.value <= 0.01

modeloharmzt <- lm(seriezt ~cos1 + sin1 + cos2+sin2, data=harmonica)
summary(modeloharmzt)

##
## Call:
## lm(formula = seriezt ~ cos1 + sin1 + cos2 + sin2, data = harmonica)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -6.9848 -0.9975 -0.0257  0.9922  6.8994
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.02994    0.10153   0.295   0.7683
## cos1         0.08741    0.14370   0.608   0.5434
## sin1        -0.05358    0.14348  -0.373   0.7091
## cos2         0.26003    0.14348   1.812   0.0709 .
## sin2         0.72177    0.14370   5.023 8.51e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.825 on 318 degrees of freedom
## (1 observation deleted due to missingness)
## Multiple R-squared:  0.08345,    Adjusted R-squared:  0.07192
## F-statistic: 7.238 on 4 and 318 DF,  p-value: 1.372e-05
```

Diferente da transformação anterior, os testes indicam estacionaridade e sazonalidade.

Questão 8

Pelos passos feitos anteriormente temos que na parte não-sanzonal, ou seja a regular, foi feita a diferenciação, assim $d = 1$. E na parte sanzonal não foi feita, assim $D = 0$. Há evidências de sanzonalidade, ou seja, interanual, assim $s = 12$. O treinamento será feito com 75% dos dados.

```
n.treinamento <- ceiling(3*n/4)
Yt.treinamento <- condados$Yt[1:n.treinamento]
```

Questão 9

Determinando ordem do modelo da série de treinamento. As malhas definidas para a ordem regressiva p e as médias móveis q , ou seja, a parte não sazonal do modelo, foram de 4. Já na parte sazonal, a ordem regressiva P e a média móvel Q , têm a malha de 2.

```
if (any(is.na(Yt.treinamento)) || any(!is.finite(Yt.treinamento))) {
  stop("Os dados de treinamento contêm valores NA ou infinitos.
       Verifique os dados.")
}

# Ajuste do modelo SARIMA usando BIC
BIC <- NULL
grid <- 0:4
Grid <- 0:2
for (p.grid in grid) {
  for (q.grid in grid) {
    for (P.grid in Grid) {
      for (Q.grid in Grid) {
        tryCatch({
          draft <- sarima(Yt.treinamento, p.grid, 1, q.grid, P = P.grid, D = 0,
                        Q = Q.grid, S = 12, no.constant = TRUE,
                        details = FALSE)
          BIC <- rbind(BIC, c(BIC = unlist(draft[4])[3], p = p.grid, q = q.grid,
                            P = P.grid, Q = Q.grid))
        }, error = function(e) {
          message("Erro com p=", p.grid, " q=", q.grid, " P=", P.grid, " Q=",
                Q.grid, ": ", e$message)
        })
      }
    }
  }
}
```

Os resultados deste código foram omitidos para que o documento ficasse mais compacto.

Questão 10

```
BIC <- data.frame(BIC)
BIC <- BIC[order(BIC$BIC.ICs.BIC),]
BIC[1:10,]
```

```
##      BIC.ICs.BIC p q P Q
## 14      3.662811 0 1 1 1
## 118     3.670995 2 3 0 0
## 19      3.673560 0 2 0 0
## 10      3.675266 0 1 0 0
```

```
## 23      3.675506 0 2 1 1
## 16      3.676119 0 1 2 0
## 59      3.677445 1 1 1 1
## 55      3.678073 1 1 0 0
## 15      3.680050 0 1 1 2
## 13      3.680637 0 1 1 0
```

O melhor modelo encontrado foi o 23, um modelo SARIMA(0,1,1)x(1,0,1) como $p = 0$, $q = 1$, $P = 1$ e $Q = 1$, não existe nenhuma ordem nas malhas definidas no último item.

Questão 11

11.1


```
fit <- sarima(Yt.treinamento, BIC[1,2], 1, BIC[1,3], P=BIC[1,4], D=0, Q=BIC[1,5],
             S=12, no.constant=TRUE)
```

```
## initial  value 0.486977
## iter    2 value 0.411268
## iter    3 value 0.394992
## iter    4 value 0.388880
## iter    5 value 0.384928
## iter    6 value 0.384282
## iter    7 value 0.384122
## iter    8 value 0.383911
## iter    9 value 0.383765
## iter   10 value 0.383635
## iter   11 value 0.382728
## iter   12 value 0.381890
## iter   13 value 0.381259
## iter   14 value 0.380991
## iter   15 value 0.380931
## iter   16 value 0.380930
## iter   17 value 0.380930
## iter   18 value 0.380928
## iter   19 value 0.380926
## iter   20 value 0.380926
## iter   21 value 0.380926
## iter   21 value 0.380926
## iter   21 value 0.380926
## final   value 0.380926
## converged
## initial  value 0.379111
## iter    2 value 0.378512
## iter    3 value 0.377789
## iter    4 value 0.374086
## iter    5 value 0.371700
```

```

## iter    6 value 0.367820
## iter    7 value 0.367523
## iter    8 value 0.367212
## iter    9 value 0.367119
## iter   10 value 0.367116
## iter   11 value 0.367104
## iter   12 value 0.367104
## iter   13 value 0.367104
## iter   14 value 0.367104
## iter   15 value 0.367104
## iter   16 value 0.367104
## iter   17 value 0.367104
## iter   17 value 0.367104
## iter   17 value 0.367104
## final   value 0.367104
## converged
## <><><><><><><><><><><><><><>
##
## Coefficients:
##      Estimate      SE t.value p.value
## ma1   -0.5116 0.0603 -8.4886      0
## sar1    0.8912 0.0871 10.2341      0
## sma1   -0.7707 0.1228 -6.2775      0
##
## sigma^2 estimated as 2.064745 on 239 degrees of freedom
##
## AIC = 3.605142  AICc = 3.605559  BIC = 3.662811
##

```




```
fit
```

```
## $fit
##
## Call:
## arima(x = xdata, order = c(p, d, q), seasonal = list(order = c(P, D, Q), period = S),
##       include.mean = !no.constant, transform.pars = trans, fixed = fixed, optim.control = list(t
##       REPORT = 1, reltol = tol))
##
## Coefficients:
##          ma1      sar1      sma1
##      -0.5116  0.8912  -0.7707
## s.e.   0.0603  0.0871  0.1228
##
## sigma^2 estimated as 2.065:  log likelihood = -432.22,  aic = 872.44
##
## $degrees_of_freedom
## [1] 239
##
## $ttable
##      Estimate      SE t.value p.value
## ma1   -0.5116 0.0603 -8.4886      0
## sar1    0.8912 0.0871 10.2341      0
## sma1   -0.7707 0.1228 -6.2775      0
##
```

```
## $ICs
##      AIC      AICc      BIC
## 3.605142 3.605559 3.662811
```


11.2

```
acf(fit[["fit"]][["residuals"]], lag=length(fit[["fit"]][["residuals"]]),
    main = "FAC dos resíduos")
```



```
pacf(fit[["fit"]][["residuals"]], lag=length(fit[["fit"]][["residuals"]]),
    main = "FACP dos resíduos")
```

FACP dos resíduos



Teste de Ljung-Box

```
LB <- NULL
for (lag in 1:30){
  LB[lag] <- Box.test(resid(fit$fit), lag = lag, type = 'Ljung-Box')$p.value
}
data.frame(p.values=LB)
```

```
##      p.values
## 1  0.4761410
## 2  0.2245768
## 3  0.3607612
## 4  0.2170559
## 5  0.2681805
## 6  0.3112658
## 7  0.4152135
## 8  0.5212602
## 9  0.4458055
## 10 0.5088666
## 11 0.5549224
## 12 0.6088818
## 13 0.6860220
## 14 0.5848631
## 15 0.6568385
## 16 0.6092470
```




```
## 17 0.5252816
## 18 0.5933901
## 19 0.5795537
## 20 0.6058458
## 21 0.3991237
## 22 0.3704225
## 23 0.4194380
## 24 0.4495682
## 25 0.5071818
## 26 0.5554558
## 27 0.5877765
## 28 0.6275006
## 29 0.5857557
## 30 0.5456846
```

11.3

```
shapiro.test(fit[["fit"]][["residuals"]])
```

```
##
## Shapiro-Wilk normality test
##
## data: fit[["fit"]][["residuals"]]
## W = 0.96652, p-value = 1.793e-05
```

```
qqnorm(fit[["fit"]][["residuals"]])
```



Questão 12


```
fitvali <- sarima(Yt, BIC[1,2], 1, BIC[1,3], P=BIC[1,4], D=0, Q=BIC[1,5], S=12,
  no.constant=TRUE)
```

```
## initial  value 0.647680
## iter   2 value 0.604103
## iter   3 value 0.548093
## iter   4 value 0.542900
## iter   5 value 0.540838
## iter   6 value 0.538255
## iter   7 value 0.522773
## iter   8 value 0.519684
## iter   9 value 0.518780
## iter  10 value 0.517721
## iter  11 value 0.517559
## iter  12 value 0.517550
## iter  13 value 0.517538
## iter  14 value 0.517535
## iter  15 value 0.517535
## iter  15 value 0.517535
## final   value 0.517535
```

```

## converged
## initial  value 0.505061
## iter    2 value 0.504561
## iter    3 value 0.504050
## iter    4 value 0.503683
## iter    5 value 0.501980
## iter    6 value 0.501130
## iter    7 value 0.501097
## iter    8 value 0.501091
## iter    9 value 0.501091
## iter   10 value 0.501091
## iter   11 value 0.501091
## iter   12 value 0.501090
## iter   13 value 0.501090
## iter   14 value 0.501090
## iter   14 value 0.501090
## iter   14 value 0.501090
## final   value 0.501090
## converged
## <><><><><><><><><><><>
##
## Coefficients:
##      Estimate      SE t.value p.value
## ma1    -0.5002 0.0571 -8.7577      0
## sar1     0.9122 0.0494 18.4560      0
## sma1    -0.7042 0.0872 -8.0745      0
##
## sigma^2 estimated as 2.680367 on 320 degrees of freedom
##
## AIC = 3.864825  AICc = 3.865057  BIC = 3.911607
##

```




```
fitvali
```

```
## $fit
##
## Call:
## arima(x = xdata, order = c(p, d, q), seasonal = list(order = c(P, D, Q), period = S),
##       include.mean = !no.constant, transform.pars = trans, fixed = fixed, optim.control = list(t
##       REPORT = 1, reltol = tol))
##
## Coefficients:
##          ma1      sar1      sma1
##       -0.5002  0.9122  -0.7042
## s.e.   0.0571  0.0494  0.0872
##
## sigma^2 estimated as 2.68:  log likelihood = -620.17,  aic = 1248.34
##
## $degrees_of_freedom
## [1] 320
##
## $ttable
##      Estimate      SE t.value p.value
## ma1   -0.5002 0.0571 -8.7577      0
## sar1   0.9122 0.0494 18.4560      0
## sma1  -0.7042 0.0872 -8.0745      0
##
```

```
## $ICs
##      AIC      AICc      BIC
## 3.864825 3.865057 3.911607
```

```
residuos <- fitvali[["fit"]][["residuals"]]
Yhat <- Yt - residuos
Y.hat <- NULL
Y.t <- NULL
for (h in (n.treinamento+1):n){
  Y.t[h+1] <- condados$Yt[h] + condados$yt[h+1]
  Y.hat[h+1] <- condados$Yt[h] - residuos[h+1]
}
condados$Yhat <- Yhat
condados$Yhat[1:n.treinamento] <- NA
getYt + geom_line(data=condados, mapping = aes(x=t, y=Yhat), linewidth = .2,
                  col='red')
```

Gráfico de evolução temporal do consumo médio de energia




```
(MAPE <- mean(abs((na.omit(Yhat)-na.omit(Yt))/na.omit(Yt)), na.rm = T)*100)
```

```
## [1] 9.632675
```

Mape de 9,63%, considerado muito bom.

Questão 13

```
fitprev <- sarima.for(as.ts(Yt), n.ahead = 12, BIC[1,2], 1, BIC[1,3],P=BIC[1,4],  
                      D=0, Q=BIC[1,5],S=12, no.constant=TRUE, plot.all = TRUE)
```



```
fitprev
```

```
## $pred  
## Time Series:  
## Start = 325  
## End = 336  
## Frequency = 1  
## [1] 11.836985 12.854043 12.775152 9.601457 8.668124 8.917097 9.640815  
## [8] 10.950014 9.649627 10.511607 9.361128 9.256287  
##  
## $se  
## Time Series:  
## Start = 325  
## End = 336  
## Frequency = 1  
## [1] 1.637183 1.830290 2.004882 2.165444 2.314895 2.455266 2.588035 2.714317  
## [9] 2.834980 2.950713 3.062074 3.169525
```

Essa previsão se limita à linearidade, estacionaridade, sazonalidade fixa, um tamanho de amostra suficientemente grande, normalidade dos resíduos e estas previsões podem ser significativamente afetadas por ruídos e comportamentos atípicos. A normalidade foi rejeitada no item “11.3” para contornar este problema se pode fazer uma transformação de dados ou utilizar técnicas de reamostragem, como bootstrap. Também seria possível pensar em modelos que tenham como base distribuições com a cauda pesada.

Questão 14

Este estudo apresentou uma análise detalhada do consumo médio diário de energia elétrica, utilizando a série temporal do consumo mensal. Iniciamos calculando o consumo médio diário e analisamos sua evolução temporal. Em seguida, aplicamos métodos estatísticos e testes de estacionaridade para entender as características da série, como autocorrelação e sazonalidade. A transformação da série por diferenciação foi fundamental para remover tendências e estabilizar a variância, permitindo que o modelo SARIMA fosse adequadamente ajustado. Utilizamos o critério de informação bayesiano de Schwarz (BIC) para selecionar o melhor modelo SARIMA, e foi selecionado o modelo SARIMA $(0,1,1) \times (1,0,1)$. O teste de Ljung-Box confirmou a adequação do modelo, porém o Shapiro-Wilk rejeitou a normalidade, sendo necessária algumas alterações para total adequação do modelo. Porém a análise foi continuada a fim de estudo, resultando em um MAPE de 9,63%, indicando um modelo preditivo muito bom. Para manter a precisão e relevância do modelo, recomendamos atualizá-lo periodicamente com novos dados à medida que estes se tornam disponíveis. Especificamente, o modelo deve ser reavaliado trimestralmente ou sempre que houver mudanças significativas nos padrões de consumo ou nas condições externas que possam afetar o consumo de energia. A reavaliação incluirá a recalibração dos parâmetros e, se necessário, a reconsideração das ordens do modelo SARIMA. Além disso, o monitoramento contínuo dos resíduos deve ser realizado para identificar qualquer sinal de não conformidade, indicando a necessidade de ajustes no modelo ou a adoção de um novo modelo mais adequado às novas condições dos dados.